

Pengenalan Aksara Jawa Tulisan Tangan untuk Klasifikasi 120 Kelas Silabik Menggunakan Augmentasi Berbasis Preservasi Struktur dan Weighted Loss pada Dataset Tidak Seimbang

1st Fathan Fardian Sanum

School of Computing

Telkom University

Bandung, Indonesia

fathansanum@student.telkomuniversity.ac.id

2nd Syahdan Rizqi Ruhendy

School of Computing

Telkom University

Bandung, Indonesia

fathansanum@student.telkomuniversity.ac.id

3rd Ardia Alif Ramadhan

School of Computing

Telkom University

Bandung, Indonesia

fathansanum@student.telkomuniversity.ac.id

Abstrak—Aksara Jawa (*Hanacaraka* / *Carakan*) merupakan sistem penulisan *abugida* yang menjadi warisan budaya penting masyarakat Jawa, Indonesia. Pengenalan otomatis aksara Jawa tulisan tangan pada cakupan penuh 120 kelas silabik, yang dibentuk dari kombinasi 20 konsonan dasar (*nglegena*) dengan 6 tanda vokal, masih sangat terbatas, terutama pada kondisi data yang tidak seimbang secara alami. Penelitian ini mengatasi celah tersebut menggunakan dataset *Indonesian Local Script Characters*, yang memiliki rasio ketidakseimbangan kelas sebesar $33,10 \times$ antara kelas mayoritas (Vokal A, hingga 695 gambar per kelas) dan kelas minoritas (Vokal E, I, O, U, dan E-taling, hanya sekitar 21 gambar per kelas). Kami mengusulkan *pipeline* persiapan data empat langkah: (1) stratified split 70:15:15 per kelas, (2) integrasi data variasi tulisan tangan, (3) augmentasi berbasis preservasi struktur (hanya transformasi fotometrik dan morfologis, tanpa transformasi geometris yang dapat mengubah makna visual aksara), dan (4) fungsi loss berbobot (*weighted cross-entropy*). Model EfficientNet-B0 dengan bobot pralatih ImageNet-1K dilatih menggunakan strategi *fine-tuning* dua fase. Selain metrik agregat, evaluasi dilaporkan secara terpisah untuk kelas mayoritas (Vokal A) dan minoritas (Vokal non-A), memberikan gambaran yang lebih transparan mengenai kemampuan generalisasi model pada kondisi ketidakseimbangan nyata.

Kata Kunci—aksara Jawa, pengenalan karakter tulisan tangan, dataset tidak seimbang, augmentasi preservasi struktur, *transfer learning*, EfficientNet-B0, *abugida*, *weighted loss*

resmi di Jawa, Indonesia [2]. Meskipun memiliki nilai sejarah dan budaya yang tinggi, tingkat penguasaan dan penggunaan aksara Jawa terus menurun akibat dominasi aksara Latin dalam sistem pendidikan modern [1], [10]. Kondisi ini menimbulkan ancaman nyata terhadap kelestarian warisan budaya tersebut.

Salah satu strategi pelestarian yang efektif adalah digitalisasi naskah melalui *Optical Character Recognition* (OCR), yang memungkinkan konversi dokumen historis ke format digital yang dapat dicari dan diakses untuk berbagai aplikasi seperti mesin penerjemah, platform pembelajaran digital, dan basis data warisan budaya. Namun, pengembangan sistem OCR yang akurat untuk aksara Jawa menghadirkan tantangan teknis tersendiri yang berakar pada kompleksitas struktur tulisannya.

Aksara Jawa diklasifikasikan sebagai *abugida* (alphasilabari), yaitu sistem tulisan di mana setiap simbol dasar merepresentasikan konsonan dengan vokal inheren, sedangkan vokal lain ditandai melalui diakritik tambahan yang disebut *sandhangan* [8], [9]. Kombinasi 20 konsonan dasar dengan 6 posisi vokal (Vokal A, E, I, O, U, dan E-taling) menghasilkan **120 kelas silabik yang berbeda**. Widiarti dan Adji [9] mencatat bahwa sistem aksara Jawa secara lengkap, termasuk bentuk *pasangan*, dapat menghasilkan lebih dari 11.000 unit silabik yang berbeda, menegaskan kompleksitas inheren sistem ini untuk keperluan OCR.

Pengenalan pada cakupan 120 kelas menghadapi dua hambatan teknis utama. Pertama, beberapa pasangan karakter

I. PENDAHULUAN

Aksara Jawa (*Hanacaraka* atau *Carakan*) adalah sistem penulisan tradisional yang telah digunakan selama berabad-abad dalam naskah sastra, dokumen keagamaan, dan catatan

memiliki kemiripan visual yang sangat tinggi. Nindya et al. [3] mengidentifikasi pasangan “ha”/“la” dengan *Character Likeness Rate* (CLR) sebesar 25,3% (keduanya merupakan cerminan horizontal yang hampir identik), serta pasangan “sa”/“da” (CLR 15,8%). Kedua, satu-satunya dataset publik yang mencakup seluruh 120 kelas silabik, yaitu *Indonesian Local Script Characters* [4], [10], memiliki distribusi kelas yang sangat tidak seimbang: kelas Vokal A rata-rata memiliki ≈ 500 gambar per kelas, sementara 100 kelas lainnya (Vokal E, I, O, U, dan E-taling) hanya memiliki ≈ 21 gambar per kelas, menghasilkan rasio ketidakseimbangan sebesar $33,10\times$.

Penelitian ini memberikan tiga kontribusi utama:

- 1) **Metodologis:** Sebuah *pipeline* data empat langkah yang menggabungkan stratified split, integrasi data variasi, dan strategi *augmentasi berbasis preservasi struktur* yang secara eksplisit mengecualikan transformasi geometris yang terbukti dapat merusak struktur visual aksara [3], [10].
- 2) **Empiris:** Evaluasi pertama pengenalan 120 kelas silabik aksara Jawa pada dataset yang tidak seimbang secara alami ($IR = 33,10\times$), melengkapi studi-studi sebelumnya yang menggunakan dataset seimbang buatan [5], [6].
- 3) **Analitis:** Pelaporan metrik kinerja secara terpisah per kelompok vokal (Vokal A vs. Vokal non-A), memberikan gambaran transparan tentang perilaku model di bawah kondisi ketidakseimbangan yang tersembunyi oleh metrik agregat.

Sisa makalah ini disusun sebagai berikut. Bagian II mengulas penelitian terkait. Bagian III mendeskripsikan dataset. Bagian IV memaparkan metode yang diusulkan. Bagian V merinci pengaturan eksperimen. Bagian VI menyajikan dan mendiskusikan hasil. Bagian VII menutup makalah.

II. TINJAUAN PUSTAKA

A. Pengenalan Aksara Jawa: Studi 120 Kelas

Susanto et al. [6] mengembangkan CNN khusus dengan empat lapisan konvolusional dan dua lapisan *fully connected* untuk klasifikasi 120 kelas, mencapai akurasi 97,29% pada dataset seimbang berisi 14.400 gambar (120 per kelas) dari 30 penulis. Kelompok yang sama [5] kemudian mengusulkan CNN 12 lapisan dengan *augmentasi selektif* (transformasi afin, proyektif, dan penskalaan minimal dengan rotasi dibatasi pada $\pm 3^\circ$ untuk menghindari perubahan makna aksara), mencapai akurasi 99,65%. Kedua studi beroperasi pada dataset yang diseimbangkan secara artifisial, sehingga kondisi data tidak seimbang secara alami belum pernah dieksplorasi. Pembatasan sudut rotasi pada [5] secara langsung menjadi motivasi strategi *augmentasi* yang diusulkan dalam penelitian ini.

B. Pengenalan Multi-Aksara Nusantara

Wisesty et al. [10] mengusulkan MNetNCR berbasis MobileNetV3 untuk lima aksara Nusantara, mencapai $F1 = 0,979$ untuk aksara Jawa (20 kelas dasar) *tanpa augmentasi*. Secara kritis, penerapan *augmentasi* justru *menurunkan* performa dari 0,9788 menjadi 0,9579, yang dikaitkan dengan transformasi yang mengganggu struktur visual khas aksara Jawa. Temuan

ini menjadi motivasi empiris utama bagi pembatasan *augmentasi* yang diterapkan dalam penelitian ini.

Nindya et al. [3] menerapkan VGG-16 pada klasifikasi multi-aksara Bali, Jawa, dan Sunda, mencapai akurasi 93,19% untuk subset Jawa (20 kelas). Penelitian ini memperkenalkan metrik CLR dan mengidentifikasi pasangan “ha”/“la” (CLR 25,3%) dan “sa”/“da” (CLR 15,8%) sebagai karakter yang paling sering tertukar karena kemiripan visualnya, mengkonfirmasi bahwa *horizontal flip* harus dihindari.

Sulistiyo et al. [4] membandingkan metode *shallow learning* (LightGBM, XGBoost, Random Forest, SVM, CatBoost) pada dataset yang sama, dengan LightGBM mencapai F1-score tertinggi sebesar 77,15% untuk aksara Jawa. Hasil ini menegaskan bahwa *deep learning* jauh mengungguli pendekatan *shallow learning* pada tugas klasifikasi multi-kelas yang kompleks.

C. Penanganan Ketidakseimbangan pada Aksara Jawa

Faizin et al. [1] dari ITS mengembangkan SkelBAGAN (*Skeleton-based Balancing GAN*) untuk dataset aksara Jawa dengan rasio ketidakseimbangan hingga $81,78\times$. SkelBAGAN mengintegrasikan *autoencoder* kerangka karakter dan *adversarial loss* berbasis kerangka untuk menghasilkan gambar sintesis yang mempertahankan integritas struktur aksara. Ini merupakan satu-satunya penelitian sebelumnya yang secara eksplisit menangani ketidakseimbangan pada pengenalan aksara Jawa, sehingga menjadi landasan komparatif bagi pendekatan tanpa GAN yang kami usulkan.

D. OCR Aksara Abugida Asia Tenggara

Wicaksono et al. [8] melakukan tinjauan literatur sistematis tentang segmentasi kata untuk aksara abugida Asia Tenggara (Thai, Burma, Lao, Khmer, Jawa, dan Sunda), menemukan bahwa tidak ada penelitian dalam lima tahun terakhir yang membahas segmentasi kata untuk aksara Jawa maupun Sunda. Widiarti dan Adji [9] menetapkan evaluasi baseline untuk OCR aksara Jawa *cetak* (bukan tulisan tangan), mencatat tantangan tambahan yang ditimbulkan oleh variasi tulisan tangan. Kedua survei ini mengkonfirmasi bahwa pengenalan karakter terisolasi, yaitu cakupan penelitian ini, merupakan batas penelitian terkini untuk OCR aksara Jawa.

III. DATASET

A. Sumber dan Struktur

Penelitian ini menggunakan dataset *Indonesian Local Script Characters*, dikurasi oleh Aditya Firman Ihsan et al. di Universitas Telkom dan tersedia di Mendeley Data. Dataset ini juga digunakan pada penelitian-penelitian sebelumnya [4], [10]. Untuk aksara Jawa, dataset terdiri dari dua sub-direktori:

- *all_class*/: 6 kelompok vokal $\times$ 20 sub-folder konsonan = 120 direktori kelas, dengan total 12.191 gambar.
- *variations*/: 8 direktori konsonan (ba, ga, ha, ka, la, nya, ra, ta) berisi 1.066 gambar yang merepresentasikan variasi gaya tulisan tangan untuk kelas Vokal A yang bersesuaian.

Gambar didominasi format JPEG (91%) dan PNG (9%), saluran warna RGB (98,3%), dengan resolusi asli $\approx 362 \times 347$

piksel. Seluruh gambar distandarisasi ke ukuran 224×224 piksel sebagai input model.

B. Distribusi Kelas dan Karakterisasi Ketidakseimbangan

Tabel I merangkum distribusi per kelompok vokal. Dua puluh kelas Vokal A masing-masing memiliki 426–695 gambar ($\mu = 499,8$), sedangkan 100 kelas non-A hanya memiliki 21–22 gambar per kelas. Rasio ketidakseimbangan (maks/min) adalah **33,10 $\times$** , dengan median per kelas sebesar 22, jauh di bawah rata-rata 101,59, yang mengkonfirmasi distribusi sangat condong ke kanan dan didominasi oleh sejumlah kecil kelas mayoritas.

TABLE I
DISTRIBUSI KELAS DATASET PER KELOMPOK VOKAL

Kelompok Vokal	Kelas	Gambar/Kelas	Total
Vokal A	20	426–695	9.995
Vokal E	20	21–22	440
Vokal I	20	21–22	440
Vokal O	20	21–22	440
Vokal U	20	21–22	440
Vokal E-taling	20	21–22	440
Total	120	21–695	12.195

IR = 33,10 $\times$; Median = 22; Rerata = 101,59; Std = 188,94

Sub-direktori *variations/* (IR = 2,87 $\times$ dalam subset ini) menyediakan gambar tambahan untuk 8 dari 20 konsonan Vokal A, digunakan pada Langkah 2 dari *pipeline* yang diusulkan.

IV. METODE YANG DIUSULKAN

A. Gambaran Umum Pipeline

Gambar 1 mengilustrasikan *pipeline* persiapan data empat langkah yang diterapkan sebelum pelatihan model. *Pipeline* ini mengubah dataset mentah yang sangat tidak seimbang menjadi set pelatihan dengan distribusi kelas yang lebih terkontrol, memungkinkan aliran gradien yang lebih adil di antara 120 kelas selama optimasi.

B. Langkah 1: Stratified Split Per Kelas

Dataset dibagi menjadi set pelatihan (70%), validasi (15%), dan pengujian (15%) menggunakan pembagian stratifikasi *per kelas*. Hal ini menjamin semua 120 kelas terwakili di setiap subset, bahkan untuk kelas minoritas yang hanya memiliki 21 gambar, menghasilkan ≈ 15 gambar pelatihan / 3 validasi / 3 pengujian per kelas minoritas sebelum augmentasi.

C. Langkah 2: Integrasi Data Variasi

Sebanyak 1.066 gambar dari *variations/* ditambahkan ke set pelatihan 8 kelas konsonan Vokal A yang bersesuaian (ba, ga, ha, ka, la, nya, ra, ta). Langkah ini meningkatkan keberagaman gaya tulisan tangan untuk kelas-kelas tersebut tanpa memerlukan pengumpulan data baru.




Fig. 1. Pipeline persiapan data empat langkah. Langkah 1–4 diterapkan secara berurutan sebelum pelatihan.

D. Langkah 3: Augmentasi Berbasis Preservasi Struktur

Ini merupakan kontribusi metodologis utama penelitian. Augmentasi diterapkan *hanya pada kelas minoritas* yang jumlah gambar pelatihannya berada di bawah ambang batas target $T = 300$ gambar, yaitu mencakup seluruh 100 kelas non-A. Gambar-gambar baru dibuat dengan mengambil sampel berulang dari gambar pelatihan yang ada dan menerapkan transformasi hingga setiap kelas mencapai T sampel.

Batasan desain yang kritis: **tidak menggunakan transformasi geometris**. Dua observasi dari literatur menjustifikasi ini: (1) Wisesty et al. [10] secara empiris menunjukkan bahwa augmentasi menurunkan kinerja pengenalan aksara Jawa, yang dikaitkan dengan transformasi yang mengganggu struktur visual karakteristik; (2) Pasangan “ha”/“la” [3] merupakan cerminan horizontal yang hampir identik, sehingga penerapan *horizontal flip* langsung menyebabkan korupsi label lintas kelas.

Tabel II mencantumkan transformasi yang diizinkan dan dilarang. Transformasi yang diizinkan menargetkan *variabilitas tampilan* (kerapatan tinta, derau pemindaian, ketebalan goresan pena) tanpa mengubah tata letak spasial karakter. Setiap gambar yang diaugmentasi dibuat dengan menerapkan 1–3 transformasi yang dipilih secara acak dari daftar yang diizinkan. Augmentasi dilakukan secara *offline* (disimpan ke disk) untuk menjamin reproduisibilitas.

E. Langkah 4: Fungsi Loss Berbobot

Setelah augmentasi, bobot kelas dihitung menggunakan rumus:

$$w_c = \frac{N}{C \cdot n_c} \quad (1)$$

TABLE II
STRATEGI AUGMENTASI BERBASIS PRESERVASI STRUKTUR

Kategori	Transformasi	Status
Fotometrik	Jitter kecerahan ($\pm 30\%$)	✓
	Jitter kontras ($\pm 30\%$)	✓
	Gaussian blur (radius 0,5–1,5 px)	✓
	Gaussian noise ($\sigma = 1\text{--}5\%$)	✓
	Penajaman ($1,2\times\text{--}2,0\times$)	✓
Morfologis	Dilasi (MaxFilter $3\times 3 / 5\times 5$)	✓
	Erosi (MinFilter $3\times 3 / 5\times 5$)	✓
Spasial	Crop acak + resize (maks 10% tepi)	✓
Geometris (dilarang)	Rotasi ($> \pm 3^\circ$)	×
	Flip horizontal / vertikal	×
	Shear / transformasi afin	×
	Elastic distortion	×

dengan N adalah total sampel pelatihan, $C = 120$ adalah jumlah kelas, dan n_c adalah jumlah sampel pelatihan pada kelas c . Formula ini setara dengan `compute_class_weight('balanced')` pada scikit-learn, yang memberikan penalti kerugian lebih besar pada kesalahan klasifikasi kelas minoritas. Bobot ini diterapkan sebagai parameter pada fungsi `CrossEntropyLoss` selama pelatihan.

F. Arsitektur Model

Penelitian ini menggunakan **EfficientNet-B0** [7] yang dilatih-awal pada ImageNet-1K. Kepala klasifikasi bawaan (1.000 kelas) digantikan dengan lapisan linear yang memetakan dari 1.280 fitur ke 120 kelas. Dengan $\approx 5,3$ juta parameter dan kompatibel dengan VRAM 8 GB, EfficientNet-B0 menawarkan keseimbangan akurasi–kompleksitas yang efisien.

G. Strategi Pelatihan

Pelatihan mengikuti pendekatan *fine-tuning* dua fase:

- **Fase 1 (epoch 1–10):** Tulang punggung (*backbone*) dibekukan; hanya kepala klasifikasi yang dilatih. Optimizer AdamW dengan $\text{lr} = 10^{-3}$, $\text{weight decay} = 5 \times 10^{-4}$. Fase ini membangun inisialisasi kepala yang stabil sebelum gradien merambat ke fitur pralatih.
- **Fase 2 (epoch 11 dan seterusnya):** Seluruh lapisan dibebaskan untuk *fine-tuning* penuh. AdamW dengan $\text{lr} = 10^{-4}$. ReduceLROnPlateau (faktor 0,5, *patience* 3) menyesuaikan laju pembelajaran berdasarkan dataran validasi. *Early stopping* dengan *patience* = 10 epoch.

Loss menggunakan `CrossEntropyLoss` berbobot sesuai persamaan (1). Citra dinormalisasi dengan statistik ImageNet ($\mu = [0,485; 0,456; 0,406]$, $\sigma = [0,229; 0,224; 0,225]$).

V. PENGATURAN EKSPERIMEN

A. Perangkat Keras dan Perangkat Lunak

Semua eksperimen dilakukan pada sistem dengan GPU NVIDIA GeForce RTX 3070 Ti (8 GB VRAM) dan CPU AMD Ryzen 5 3600. Perangkat lunak: Python 3.10, PyTorch 2.9.1 (CUDA 13.0), torchvision 0.24.1, scikit-learn. Seluruh *random seed* ditetapkan pada nilai 42 untuk reproduibilitas. Ukuran *batch*: 32; jumlah *worker* DataLoader: 4.

B. Metrik Evaluasi

Metrik berikut dilaporkan pada set pengujian (15% per kelas):

- **Keseluruhan:** Akurasi Top-1, Akurasi Top-5, F1-score makro, F1-score tertimbang, presisi dan *recall* makro.
- **Per kelompok vokal:** Akurasi, F1-score makro, presisi, dan *recall* dihitung secara terpisah untuk (a) 20 kelas Vokal A (mayoritas) dan (b) masing-masing dari lima kelompok vokal non-A (minoritas), yang merupakan kontribusi analitis utama penelitian ini.
- **Analisis konfusi:** 10 pasangan karakter yang paling sering tertukar dari matriks konfusi 120×120 , dikaitkan dengan nilai CLR dari literatur [3].

VI. HASIL DAN PEMBAHASAN

A. Kinerja Keseluruhan

Tabel III merangkum kinerja keseluruhan pada set pengujian untuk EfficientNet-B0 dengan *pipeline* yang diusulkan.

TABLE III
HASIL EVALUASI KESELURUHAN: EFFICIENTNET-B0 (120 KELAS)

Metrik	Nilai
Akurasi Top-1	–
Akurasi Top-5	–
Presisi Makro	–
<i>Recall</i> Makro	–
F1-score Makro	–
F1-score Tertimbang	–

[Akan diperbarui setelah eksperimen selesai.]

B. Analisis Per Kelompok Vokal

Tabel IV menyajikan hasil yang didisagregasi per kelompok vokal. Kesenjangan kinerja antara Vokal A (mayoritas, ≈ 350 gambar pelatihan per kelas setelah pembagian) dan Vokal non-A (minoritas, ≈ 300 gambar pelatihan setelah augmentasi) secara langsung mengukur efek residual ketidakseimbangan kelas setelah *pipeline* diterapkan. Analisis ini, yang tidak ada dalam semua studi 120 kelas sebelumnya, memberikan wawasan tentang apakah kinerja kelas minoritas dikorbankan demi akurasi agregat.

TABLE IV
HASIL EVALUASI PER KELOMPOK VOKAL

Kelompok Vokal	Kl.	Sampel	Akurasi (%)	F1 Makro
Vokal A (mayoritas)	20	–	–	–
Vokal E	20	–	–	–
Vokal I	20	–	–	–
Vokal O	20	–	–	–
Vokal U	20	–	–	–
Vokal E-taling	20	–	–	–
Total	120	–	–	–

[Akan diperbarui setelah eksperimen selesai.]

C. Analisis Konfusi Karakter

Berdasarkan literatur, pasangan karakter yang paling sering diperkirakan tertukar adalah “ha”/“la” (CLR 25,3%) dan “sa”/“da” (CLR 15,8%) [3]. Analisis dari matriks konfusi 120×120 akan memverifikasi apakah strategi augmentasi berbasis preservasi struktur berhasil mengurangi kebingungan lintas kelas untuk pasangan-pasangan tersebut, dibandingkan dengan model yang dilatih tanpa batasan augmentasi. [Akan diperbarui.]

D. Perbandingan dengan Penelitian Sebelumnya

Tabel V mengontekstualisasikan penelitian ini dalam literatur pengenalan aksara Jawa yang ada. Perbedaan utama pendekatan yang diusulkan adalah kombinasi cakupan 120 kelas dan kondisi pelatihan yang tidak seimbang secara alami, suatu konfigurasi yang belum pernah ditangani oleh penelitian sebelumnya.

TABLE V
PERBANDINGAN DENGAN PENELITIAN PENGENALAN AKSARA JAWA

Studi	Kl.	Seimbang?	Metrik Terbaik
Susanto et al. [6]	120	Ya	Akurasi 97,29%
Susanto et al. [5]	120	Ya	Akurasi 99,65%
Ifriza et al. [2]	20	Ya	Akurasi 95,53%
Wisesty et al. [10]	20	Ya	F1 = 0,979
Nindya et al. [3]	20	Ya	Akurasi 93,19%
Faizin et al. [1]	20	Tidak	Berbasis GAN
Usulan ini	120	Tidak	–

“Seimbang?” = apakah dataset pelatihan diseimbangkan secara artifisial.

VII. KESIMPULAN

Makalah ini memaparkan *pipeline* data empat langkah dan kerangka kerja *transfer learning* EfficientNet-B0 untuk pengenalan 120 kelas aksara Jawa tulisan tangan di bawah ketidakseimbangan kelas yang parah ($IR = 33,10 \times$). Kontribusi metodologis utama adalah strategi augmentasi berbasis preservasi struktur yang secara eksplisit mengecualikan transformasi geometris yang terbukti mengubah makna visual aksara [3],

[10]. Dikombinasikan dengan stratified split, integrasi data variasi, dan *weighted cross-entropy loss*, *pipeline* ini menangani tantangan persiapan data yang spesifik terhadap domain ini. Protokol evaluasi berlapis (keseluruhan dan per kelompok vokal) memberikan penilaian yang lebih transparan terhadap perilaku model di bawah ketidakseimbangan kelas dibandingkan metrik agregat saja.

Penelitian lanjutan mencakup: (i) sintesis kelas minoritas berbasis GAN sebagaimana [1] sebagai sumber augmentasi komplementer; (ii) perbandingan multi-arsitektur (MobileNetV3, ResNet-18, VGG-16) untuk mengidentifikasi *tradeoff* akurasi–efisiensi yang optimal untuk *deployment*; dan (iii) perluasan ke pengenalan tingkat kata termasuk bentuk *pasangan* (penggabungan konsonan), yang merupakan batas terbuka berikutnya sebagaimana diidentifikasi oleh [8].

DAFTAR PUSTAKA

- [1] M. A. Faizin, N. Suciati, dan C. Fatichah, “Handling imbalance in Javanese manuscript character dataset using skeleton-based balancing generative adversarial networks,” *Jurnal RESTI (Rekayasa Sistem dan Teknologi Informasi)*, vol. 9, no. 4, hal. 820–831, 2025.
- [2] Y. N. Ifriza et al., “Optimizing Javanese script recognition using fine-tuned ResNet-18 and transfer learning,” *International Journal of Artificial Intelligence (IJ-AI)*, vol. 15, no. 1, hal. 443–453, 2026.
- [3] T. P. Nindya, M. D. Sulistiyo, dan U. N. Wisesty, “Recognition of Balinese, Javanese, and Sundanese scripts using CNN with VGG-16 architecture,” dalam *Proc. 2025 Int. Conf. Data Science and Its Applications (ICoDSA)*, 2025, hal. 1221–1226.
- [4] M. D. Sulistiyo et al., “Aksarawa: Comparative study of shallow learning for OCR of Nusantara scripts,” *Jurnal RESTI*, vol. 9, no. 6, hal. 1537–1546, 2025.
- [5] A. Susanto et al., “Handwritten Javanese script recognition method based 12-layers deep convolutional neural network and data augmentation,” *International Journal of Artificial Intelligence (IJ-AI)*, vol. 12, no. 3, hal. 1448–1458, 2023.
- [6] A. Susanto, I. U. W. Mulyono, C. A. Sari, E. H. Rachmawanto, dan D. R. I. M. Setiadi, “Improved Javanese script recognition using custom model of convolution neural network,” *International Journal of Electrical and Computer Engineering (IJECE)*, vol. 13, no. 6, hal. 6629–6636, 2023.
- [7] M. Tan dan Q. V. Le, “EfficientNet: Rethinking model scaling for convolutional neural networks,” dalam *Proc. Int. Conf. Machine Learning (ICML)*, 2019, hal. 6105–6114.
- [8] B. A. Wicaksono, B. S. Hantono, dan T. B. Adji, “Word segmentation task for Southeast Asian abugida scripts: A systematic literature review,” dalam *Proc. 2024 2nd Int. Conf. Technology Innovation and Its Applications (ICTIIA)*, 2024.
- [9] R. Widiarti dan F. T. Adji, “A baseline evaluation of OCR segmentation and classification methods for printed Javanese script,” *Engineering, Technology & Applied Science Research (ETASR)*, vol. 16, no. 1, hal. 31699–31705, 2026.
- [10] U. N. Wisesty et al., “MNetNCR: MobileNet model for efficient traditional Nusantara script character recognition,” *International Journal of Artificial Intelligence (IJ-AI)*, vol. 15, no. 2, hal. 1513–1528, 2026.