

Comparative Study of Transfer Learning Architectures for 120-Class Handwritten Javanese Script Recognition Under Severe Class Imbalance

1st Fathan Fardian Sanum

School of Computing
Telkom University
Bandung, Indonesia

fathansanum@student.telkomuniversity.ac.id

2nd Syahdan Rizqi Ruhendy

School of Computing
Telkom University
Bandung, Indonesia
syahdanruhendy@student.
telkomuniversity.ac.id

3rd Ardia Alif Ramadhan

School of Computing
Telkom University
Bandung, Indonesia
ardiarahaman@student.telkomuniversity.ac.id

Abstrak—Aksara Jawa (*Hanacaraka*) adalah sistem penulisan tradisional yang menghadapi ancaman kepunahan fungsional akibat berkurangnya generasi yang mampu membaca dan menulisnya, menjadikan digitalisasi melalui pengenalan karakter otomatis sebagai strategi pelestarian yang mendesak. Tantangan yang belum pernah ditangani secara bersamaan dalam literatur adalah cakupan penuh 120 kelas silabik dan ketidakseimbangan data yang ekstrem, dengan rasio ketidakseimbangan 33.10 $\times$ (kelas terbanyak 695 gambar berbanding kelas terkecil 21 gambar) antara kelas Vokal A sebagai mayoritas dan lima kelompok vokal lainnya. Penelitian ini mengusulkan *pipeline* persiapan data empat langkah berbasis preservasi struktur yang secara eksplisit menghindari augmentasi geometris untuk menjaga integritas visual aksara, dikombinasikan dengan fungsi *loss* berbobot untuk mengompensasi ketidakseimbangan kelas. Empat arsitektur *transfer learning*, yaitu EfficientNet-B0, ResNet-18, VGG-16, dan MobileNetV3-Large, dievaluasi secara komparatif menggunakan *pipeline* yang identik, dengan metrik dilaporkan terpisah untuk kelas mayoritas dan minoritas. EfficientNet-B0 mencapai akurasi 97.08% dengan F1-score makro 0.9110, sebanding dengan studi yang menggunakan dataset seimbang secara artifisial, sementara ResNet-18 menunjukkan kesenjangan F1 antara kelas mayoritas dan minoritas hanya 0.0004. Hasil ini membuktikan bahwa ketidakseimbangan data yang ekstrem dapat diatasi dengan *pipeline* yang tepat sasaran, dan menegaskan bahwa analisis per kelompok kelas diperlukan untuk mengungkap kemampuan generalisasi model yang tersembunyi oleh metrik agregat.

Kata Kunci—*Abugida*, aksara Jawa, augmentasi preservasi struktur, dataset tidak seimbang, EfficientNet-B0, MobileNetV3-Large, pengenalan karakter tulisan tangan, ResNet-18, *transfer learning*, VGG-16, *weighted loss*

I. PENDAHULUAN

Aksara Jawa (*Hanacaraka*) adalah sistem penulisan *abugida* yang menggabungkan 20 konsonan dasar dengan enam penanda vokal menjadi 120 kelas silabik [1]. Dominasi aksara Latin dalam pendidikan modern telah menyebabkan penurunan penguasaan lintas generasi [2], [3], menjadikan digitalisasi via *Optical Character Recognition* (OCR) sebagai intervensi pelestarian yang mendesak [4]. Tantangan utamanya adalah

dataset publik satu-satunya yang mencakup 120 kelas, *Indonesian Local Script Characters* [3], memiliki ketidakseimbangan ekstrem: Vokal A rata-rata 500 gambar per kelas berbanding 100 kelas non-A yang hanya sekitar 21 gambar, menghasilkan rasio 33.10 $\times$.

Transfer learning berbasis CNN terbukti efektif untuk pengenalan karakter tulisan tangan aksara regional dengan data terbatas [5], [6], mengungguli metode *shallow learning* secara signifikan [7]. Dikombinasikan dengan fungsi *loss* berbobot, pendekatan ini menjadi kerangka yang tepat untuk menangani sekaligus kompleksitas visual aksara Jawa dan ketidakseimbangan kelasnya.

Studi terdahulu meninggalkan tiga celah yang belum dijawab secara bersamaan: Susanto et al. [8] mencapai akurasi 99.65% pada 120 kelas namun pada dataset seimbang secara artifisial, sementara Wisesty et al. [3] menemukan augmentasi geometris justru menurunkan kinerja aksara Jawa. Ketiga celah tersebut adalah pengenalan 120 kelas pada kondisi ketidakseimbangan *alami*, strategi augmentasi yang aman secara struktural, dan evaluasi komparatif lintas arsitektur.

Penelitian ini menutup ketiga celah tersebut dengan mengusulkan *pipeline* persiapan data empat langkah berbasis preservasi struktur dan mengevaluasi empat arsitektur (EfficientNet-B0, ResNet-18, VGG-16, MobileNetV3-Large) secara komparatif. EfficientNet-B0 mencapai akurasi 97.08%, sementara ResNet-18 menunjukkan kesenjangan F1 antar kelompok vokal hanya 0.0004, temuan yang hanya terungkap melalui analisis per kelompok vokal.

II. TINJAUAN PUSTAKA

Studi-studi berikut merupakan referensi terdekat dengan penelitian ini karena secara langsung menargetkan cakupan penuh 120 kelas silabik aksara Jawa, sehingga menjadi tolok ukur utama yang harus dilampaui. Susanto et al. [9] mengembangkan CNN khusus dengan empat lapisan konvolusional

dan dua lapisan *fully connected* untuk klasifikasi 120 kelas, mencapai akurasi 97.29% pada dataset seimbang berisi 14,400 gambar dari 30 penulis. Kelompok yang sama [8] kemudian mengusulkan CNN 12 lapisan dengan augmentasi selektif, di mana rotasi dibatasi pada $\pm 3^\circ$ untuk menghindari perubahan makna visual aksara, dan berhasil mencapai akurasi 99.65%. Meskipun angka akurasi keduanya tinggi, seluruh eksperimen dilakukan pada dataset yang diseimbangkan secara artifisial dengan jumlah sampel yang sama persis tiap kelas, sehingga performa model pada kondisi distribusi data yang tidak seimbang secara alami sama sekali belum pernah dieksplorasi.

Selain studi yang menargetkan 120 kelas secara khusus, sejumlah penelitian pada cakupan aksara Nusantara yang lebih luas memberikan wawasan berharga tentang pilihan arsitektur, perilaku augmentasi, dan batas kemampuan model pada aksara Jawa 20 kelas dasar. Wisesty et al. [3] mengusulkan MNetNCR berbasis MobileNetV3 [10] untuk lima aksara Nusantara dan mencapai $F1=0.979$ untuk aksara Jawa tanpa augmentasi sama sekali. Yang lebih penting, penerapan augmentasi pada model ini justru menurunkan performa menjadi 0.9579 karena transformasi geometris merusak struktur visual khas aksara Jawa, sebuah peringatan empiris yang menjadi landasan utama desain strategi augmentasi penelitian ini. Nindya et al. [6] menerapkan VGG-16 [11] pada klasifikasi multi-aksara Bali, Jawa, dan Sunda, mencapai akurasi 93.19% untuk subset Jawa, sekaligus memperkenalkan metrik *Character Likeness Rate* (CLR) yang mengidentifikasi pasangan “ha”/“la” (CLR 25.3%) dan “sa”/“da” (CLR 15.8%) sebagai karakter yang paling rentan tertukar akibat kemiripan visualnya. Di sisi lain, Sulistiyo et al. [7] membandingkan berbagai metode *shallow learning* pada dataset yang sama dan menemukan bahwa LightGBM hanya mencapai F1-score 77.15%, jauh di bawah pendekatan berbasis CNN, sehingga mempertegas keunggulan *deep learning* untuk tugas ini. Ifriza et al. [5] menunjukkan bahwa ResNet-18 [12] yang di-*fine-tune* dengan strategi *transfer learning* mampu mencapai akurasi 95.53% hanya dari 1,562 gambar aksara Jawa 20 kelas, menjadikannya satu-satunya rujukan *transfer learning* berbasis ResNet untuk aksara Jawa sebelum penelitian ini. Keseluruhan studi pada bagian ini, meskipun informatif, terbatas pada dataset yang seimbang dan tidak pernah menguji ketahanan model terhadap ketidakseimbangan kelas yang ekstrem.

Ketidakseimbangan kelas merupakan aspek kritis yang diabaikan oleh hampir seluruh studi aksara Jawa, padahal kondisi ini adalah karakteristik alami dari dataset yang tersedia secara publik. Faizin et al. [2] adalah satu-satunya penelitian yang secara eksplisit menangani masalah ini, dengan mengembangkan SkelBAGAN (*Skeleton-based Balancing GAN*) untuk dataset aksara Jawa yang memiliki rasio ketidakseimbangan hingga $81.78\times$. SkelBAGAN mengintegrasikan *autoencoder* berbasis kerangka karakter dan *adversarial loss* untuk menghasilkan citra sintesis yang mempertahankan integritas struktur aksara, dan terbukti meningkatkan performa pengenalan pada kelas minoritas secara signifikan. Keterbatasannya terletak pada kompleksitas arsitektur GAN yang membutuhkan sumber daya komputasi besar, serta cakupannya yang masih terbatas pada

20 kelas dasar dan belum diuji pada skenario 120 kelas silabik penuh. Penelitian ini mengisi celah tersebut dengan pendekatan yang lebih ringan, yaitu augmentasi berbasis preservasi struktur dan fungsi *loss* berbobot, tanpa memerlukan pelatihan jaringan generatif tambahan.

Untuk memahami posisi penelitian ini dalam lanskap yang lebih luas, tinjauan terhadap studi OCR lintas aksara abugida Asia Tenggara memberikan konteks mengenai sejauh mana riset di bidang ini telah berkembang. Wicaksono et al. [1] melakukan tinjauan literatur sistematis pada enam aksara abugida Asia Tenggara dan menemukan bahwa tidak ada penelitian dalam lima tahun terakhir yang membahas segmentasi kata untuk aksara Jawa maupun Sunda, mengkonfirmasi bahwa pengenalan karakter terisolasi masih merupakan batas terdepan riset OCR aksara Jawa. Widiarti dan Adji [4] menetapkan evaluasi baseline untuk OCR aksara Jawa *cetak*, bukan tulisan tangan, dan mencatat bahwa variasi gaya penulisan tangan menambah lapisan tantangan yang jauh lebih kompleks dibandingkan aksara cetak. Kedua studi ini secara bersama menggarisbawahi bahwa domain pengenalan karakter aksara Jawa tulisan tangan, khususnya pada cakupan 120 kelas dengan data yang tidak seimbang, masih sangat terbuka dan menjadi motivasi langsung penelitian ini.

III. DATASET DAN PENGATURAN EKSPERIMEN

Penelitian ini menggunakan dataset *Indonesian Local Script Characters*, dikurasi oleh Aditya Firman Ihsan et al. di Universitas Telkom dan tersedia di Mendeley Data, yang juga digunakan oleh penelitian-penelitian sebelumnya [3], [7]. Untuk subset aksara Jawa, dataset terdiri dari dua bagian dengan total 13,257 gambar: sub-direktori *all_class/* yang memuat 12,191 gambar dalam 120 kelas silabik ($6 \text{ vokal} \times 20 \text{ konsonan}$), serta sub-direktori *variations/* yang memuat 1,066 gambar variasi gaya tulisan tangan untuk 8 konsonan (ba, ga, ha, ka, la, nya, ra, ta) pada kelompok Vokal A. Gambar didominasi format JPEG (91%) dengan saluran warna RGB (98.3%) dan resolusi asli rata-rata 362×347 piksel, kemudian distandarisasi ke 224×224 piksel sebagai input model.

Distribusi kelas dalam dataset ini sangat tidak seimbang secara alami, sebagaimana dirangkum pada Tabel I. Dua puluh kelas Vokal A memiliki 426–695 gambar per kelas ($\mu = 499.8$), sementara 100 kelas non-A hanya memiliki 21–22 gambar per kelas, menghasilkan rasio ketidakseimbangan $33.10\times$ (kelas terbanyak/terkecil: $695/21$) dengan median per kelas hanya 22, jauh di bawah rata-rata 101.59. Ketidakseimbangan ini menjadi tantangan utama yang seluruh tahapan *pipeline* dirancang untuk mengatasinya.

Dataset dibagi secara stratifikasi per kelas dengan rasio 70:15:15 menjadi set pelatihan (8,483 gambar asli), validasi (1,789 gambar), dan pengujian (1,919 gambar). Stratifikasi per kelas menjamin seluruh 120 kelas terwakili di setiap subset, termasuk kelas minoritas yang hanya memiliki 21 gambar. Setelah proses augmentasi pada set pelatihan, jumlah total sampel latih meningkat menjadi 38,510 gambar. Seluruh gambar dikonversi ke *grayscale* 3-channel dan dinormalisasi

TABLE I
DISTRIBUSI KELAS DATASET PER KELOMPOK VOKAL

Kelompok Vokal	Kelas	Gambar/Kelas	Total
Vokal A	20	426–695	9,995
Vokal E	20	21–22	440
Vokal I	20	21–22	440
Vokal O	20	21–22	440
Vokal U	20	21–22	440
Vokal E-taling	20	21–22	440
Total	120	21–695	12,191

IR = $33.10\times$, median = 22.




Fig. 1. Pipeline persiapan data empat langkah yang diterapkan secara berurutan sebelum pelatihan model.

menggunakan statistik ImageNet ($\mu = [0.485; 0.456; 0.406]$, $\sigma = [0.229; 0.224; 0.225]$).

IV. METODE YANG DIUSULKAN

A. Gambaran Umum Pipeline

Tantangan utama pada penelitian ini bukan terletak pada arsitektur model, melainkan pada kondisi data, yaitu ketidakseimbangan ekstrem antara kelas Vokal A dan kelas non-A yang membuat strategi pelatihan konvensional menghasilkan model yang bias secara sistematis terhadap kelas mayoritas. Untuk mengatasi hal ini, penelitian mengusulkan sebuah *pipeline* persiapan data empat langkah yang dieksekusi secara berurutan sebelum proses pelatihan dimulai. Setiap langkah dirancang untuk menangani satu aspek spesifik dari masalah distribusi data, mulai dari menjaga representasi kelas minoritas dalam split, menambah keragaman data tanpa pengumpulan baru, mengisi kelas minoritas dengan augmentasi yang aman secara struktural, hingga memberikan bobot penalti yang proporsional saat pelatihan. Fig. 1 mengilustrasikan alur keseluruhan *pipeline* ini.

B. Langkah 1: Stratified Split Per Kelas

Dataset dibagi menjadi set pelatihan (70%), validasi (15%), dan pengujian (15%) menggunakan pembagian stratifikasi *per kelas*. Hal ini menjamin semua 120 kelas terwakili di setiap subset, bahkan untuk kelas minoritas yang hanya memiliki 21 gambar, menghasilkan ≈ 15 gambar pelatihan, 3 gambar validasi, dan 3 gambar pengujian per kelas minoritas sebelum augmentasi. Pembagian ini menghasilkan 1,789 gambar validasi dan 1,919 gambar pengujian.

TABLE II
STRATEGI AUGMENTASI BERBASIS PRESERVASI STRUKTUR

Kategori	Transformasi	Status
Fotometrik	Jitter kecerahan ($\pm 30\%$)	✓
	Jitter kontras ($\pm 30\%$)	✓
	Gaussian blur (radius 0.5–1.5 px)	✓
	Gaussian noise ($\sigma = 1\text{--}5\%$)	✓
	Penajaman ($1.2\times\text{--}2.0\times$)	✓
Morfologis	Dilasi (MaxFilter $3\times 3 / 5\times 5$)	✓
	Erosi (MinFilter $3\times 3 / 5\times 5$)	✓
Spasial	Crop acak + resize (maks 10% tepi)	✓
Geometris (dilarang)	Rotasi ($> \pm 3^\circ$)	×
	Flip horizontal / vertikal	×
	Shear / transformasi afin	×
	Elastic distortion	×

C. Langkah 2: Integrasi Data Variasi

Sebanyak 1,066 gambar dari *variations/* ditambahkan ke set pelatihan 8 kelas konsonan Vokal A yang bersesuaian (ba, ga, ha, ka, la, nya, ra, ta). Langkah ini meningkatkan keberagaman gaya tulisan tangan untuk kelas-kelas tersebut tanpa memerlukan pengumpulan data baru.

D. Langkah 3: Augmentasi Berbasis Preservasi Struktur

Ini merupakan kontribusi metodologis utama penelitian. Augmentasi diterapkan *hanya pada 100 kelas non-A* hingga setiap kelas mencapai target $T = 300$ gambar latih. Gambar-gambar baru dibuat dengan mengambil sampel berulang dari gambar pelatihan yang ada dan menerapkan transformasi hingga setiap kelas mencapai T sampel.

Batasan desain yang paling kritis adalah larangan penggunaan transformasi geometris dalam bentuk apapun. Wisesty et al. [3] secara empiris menunjukkan bahwa augmentasi justru menurunkan kinerja pengenalan aksara Jawa karena transformasi mengubah karakteristik visual yang membedakan antarkelas. Hal ini diperkuat oleh temuan Nindya et al. [6] bahwa pasangan “ha” dan “la” merupakan cerminan horizontal yang hampir identik, sehingga penerapan *horizontal flip* akan langsung menciptakan label yang ambigu secara lintas kelas.

Tabel II mencantumkan transformasi yang diizinkan dan dilarang. Transformasi yang diizinkan menargetkan *variabilitas tampilan* (kerapatan tinta, derau pemindaian, ketebalan goresan pena) tanpa mengubah tata letak spasial karakter. Setiap gambar yang diaugmentasi dibuat dengan menerapkan 1–3 transformasi yang dipilih secara acak dari daftar yang diizinkan. Augmentasi dilakukan secara *offline* (disimpan ke disk) untuk menjamin reproduktibilitas. Hasil akhir set pelatihan setelah augmentasi berjumlah 38,510 gambar, meningkat sekitar $4.0\times$ dari 9,549 gambar sebelum augmentasi (8,483 latih asli ditambah 1,066 gambar variasi).

TABLE III
ARSITEKTUR CNN YANG DIBANDINGKAN

Arsitektur	Parameter	Relevansi Literatur
EfficientNet-B0 [13]	~5.3 juta	–
MobileNetV3-Large [10]	~5.4 juta	Wisesty et al. [3]
ResNet-18 [12]	~11.7 juta	Ifriza et al. [5]
VGG-16 [11]	~138 juta	Nindya et al. [6]

E. Langkah 4: Fungsi Loss Berbobot

Setelah augmentasi, bobot kelas dihitung menggunakan rumus:

$$w_c = \frac{N}{C \cdot n_c} \quad (1)$$

dengan N adalah total sampel pelatihan, $C = 120$ adalah jumlah kelas, dan n_c adalah jumlah sampel pelatihan pada kelas c . Formula ini setara dengan `compute_class_weight('balanced')` pada scikit-learn, yang memberikan penalti kerugian lebih besar pada kesalahan klasifikasi kelas minoritas. Bobot ini diterapkan sebagai parameter pada fungsi `CrossEntropyLoss` selama pelatihan.

F. Arsitektur Model

Setelah *pipeline* data ditetapkan, tahap berikutnya adalah memilih arsitektur model yang akan dievaluasi. Empat arsitektur CNN dengan bobot prelatih ImageNet-1K dipilih berdasarkan dua kriteria yang saling melengkapi. Kriteria pertama adalah keterwakilan kelompok arsitektur yang berbeda secara konseptual, mencakup arsitektur berbasis efisiensi komposisi (EfficientNet), koneksi residual (ResNet), *depthwise separable convolution* (MobileNetV3), dan blok konvolusional dalam (VGG). Kriteria kedua adalah keterkaitan langsung dengan penelitian aksara Jawa sebelumnya, sehingga perbandingan dapat dilakukan secara adil terhadap pilihan arsitektur yang sudah dilaporkan dalam literatur. Tabel III merangkum keempat arsitektur beserta rujukan literatur yang relevan. Kepala klasifikasi setiap arsitektur digantikan dengan lapisan linear yang memetakan ke 120 kelas, sedangkan seluruh bobot *backbone* diinisialisasi dari prelatih ImageNet-1K.

G. Strategi Pelatihan

Semua model mengikuti strategi *fine-tuning* dua fase yang seragam untuk memastikan perbandingan yang adil lintas arsitektur. Pada Fase 1 selama 10 epoch, seluruh parameter *backbone* dibekukan dan hanya kepala klasifikasi yang dilatih menggunakan optimizer Adam dengan *learning rate* yang lebih tinggi. Fase ini bertujuan membangun inisialisasi kepala yang stabil sebelum gradien merambat ke lapisan-lapisan fitur prelatih yang lebih sensitif. Pada Fase 2 yang berlangsung hingga 90 epoch, seluruh lapisan dibuka untuk *fine-tuning* penuh dengan *learning rate* yang lebih rendah. Selama Fase 2, penjadwal `ReduceLROnPlateau` dengan faktor

TABLE IV
KONFIGURASI HYPERPARAMETER PER ARSITEKTUR

Arsitektur	LR Fase 1	LR Fase 2	WD	ES
EfficientNet-B0	10^{-3}	10^{-4}	10^{-5}	10
MobileNetV3-Large	10^{-3}	10^{-4}	10^{-6}	8
ResNet-18	2×10^{-3}	2×10^{-4}	10^{-5}	12
VGG-16	5×10^{-4}	2×10^{-5}	10^{-4}	15

WD = weight decay. ES = early stopping patience.

0.5 dan *patience* 3 secara adaptif menurunkan laju pembelajaran ketika validasi *loss* stagnan, sementara *early stopping* menghentikan pelatihan apabila tidak ada perbaikan selama sejumlah epoch sesuai Tabel IV. Seluruh model dilatih menggunakan `CrossEntropyLoss` berbobot sesuai (1). Konfigurasi hyperparameter lengkap per arsitektur ditunjukkan pada Tabel IV.

Seluruh eksperimen dijalankan pada GPU NVIDIA GeForce RTX 3070 Ti (8GB VRAM) dengan CPU AMD Ryzen 5 3600, menggunakan Python 3.10, PyTorch 2.9.1 (CUDA 13.0), torchvision 0.24.1, dan scikit-learn. Seluruh *random seed* ditetapkan pada nilai 42 untuk reproduisibilitas, dengan ukuran *batch* 32 dan 3 *worker* `DataLoader`.

Evaluasi dilakukan pada set pengujian (1,919 sampel) menggunakan akurasi Top-1, F1-score makro, dan F1-score tertimbang sebagai metrik keseluruhan. F1-score makro dipilih sebagai metrik utama karena memberikan bobot yang sama pada setiap kelas tanpa dipengaruhi oleh dominasi kelas mayoritas. Sebagai kontribusi analitis utama, F1-score makro juga dihitung secara terpisah untuk kelompok Vokal A (20 kelas mayoritas, sekitar 1,519 sampel uji) dan kelompok Vokal non-A (100 kelas minoritas, 400 sampel uji), dan selisih absolut antara keduanya digunakan untuk mengukur keseimbangan generalisasi model.

V. HASIL DAN PEMBAHASAN

A. Perbandingan Kinerja Keseluruhan

Tabel V merangkum kinerja semua arsitektur pada set pengujian. EfficientNet-B0 mencapai akurasi tertinggi 97.08% dengan F1-score makro 0.9110, sementara ResNet-18 mencapai F1-score makro tertinggi (0.9180). MobileNetV3-Large dan VGG-16 menunjukkan kinerja lebih rendah meskipun masing-masing memiliki 5.4 dan 138 juta parameter, mengindikasikan bahwa jumlah parameter saja bukan penentu performa pada kondisi *imbalanced* ini.

B. Analisis Kesenjangan Vokal A vs. Vokal non-A

Kolom Kesenjangan pada Tabel V mengungkap dua pola penting yang tersembunyi oleh metrik agregat dan menjadi kontribusi analitis utama penelitian ini.

EfficientNet-B0 memperlihatkan pola yang khas pada kondisi *imbalanced*, di mana F1 Vokal A yang sangat tinggi (0.9902) berbanding dengan F1 Vokal non-A yang lebih rendah (0.8783), menghasilkan kesenjangan 0.1119. Ini mengkonfirmasi bahwa meskipun akurasi agregat tinggi, model masih

TABLE V
PERBANDINGAN KINERJA DAN ANALISIS KESENJANGAN EMPAT ARSITEKTUR PADA SET PENGUJIAN 120 KELAS

Arsitektur	Akurasi (%)	F1 Makro	F1 Vokal A	F1 Vokal non-A	Kesenjangan	Epoch
EfficientNet-B0	97.08	0.9110	0.9902	0.8783	0.1119	50
ResNet-18	96.93	0.9180	0.8972	0.8976	0.0004	36
VGG-16	93.38	0.7867	0.9824	0.7402	0.2422	36
MobileNetV3-Large	90.83	0.6935	0.9714	0.6321	0.3393	52

Kesenjangan = |F1 Vokal A - F1 non-A|.

memiliki bias residual terhadap kelas mayoritas yang tidak sepenuhnya dihilangkan oleh *pipeline* augmentasi dan fungsi *loss* berbobot.

Temuan yang paling mengejutkan datang dari ResNet-18, yang menunjukkan kesenjangan F1 antara Vokal A dan Vokal non-A hanya sebesar 0.0004 (0.8972 vs. 0.8976), sebuah angka yang secara praktis tidak berbeda. Hal ini tidak diduga sebelumnya karena ResNet-18 bukan arsitektur dengan akurasi tertinggi, namun justru arsitektur yang paling berhasil menggeneralisasi secara seimbang ke kelas minoritas. Kemampuan ini kemungkinan berakar pada mekanisme *residual connection* yang memungkinkan gradien mengalir lebih stabil ke lapisan awal, sehingga fitur visual level rendah yang relevan untuk aksara minoritas, yang hanya memiliki sekitar 300 gambar latih hasil augmentasi, tetap dapat dipelajari tanpa terdistorsi oleh dominasi gradien kelas mayoritas. Temuan semacam ini tidak mungkin terlihat pada studi sebelumnya yang menggunakan dataset seimbang, karena kesenjangan mayoritas-minoritas tidak pernah menjadi variabel yang diukur.

VGG-16 dan MobileNetV3-Large menunjukkan kesenjangan yang lebih besar, yaitu 0.2422 dan 0.3393. Untuk VGG-16, kesenjangan yang besar meskipun akurasi keseluruhan cukup tinggi (93.38%) mencerminkan arsitektur yang lebih mudah mengoptimalkan kelas mayoritas secara berlebihan. MobileNetV3-Large, yang pernah menjadi pilihan terbaik Wistey et al. [3] pada dataset seimbang 20 kelas, justru menunjukkan performa paling lemah di antara keempat arsitektur pada kondisi *imbalanced* 120 kelas ini.

C. Analisis Kurva Pelatihan

Fig. 2 dan 3 menampilkan kurva pelatihan dua arsitektur terbaik. Transisi Fase 1 ke Fase 2 (epoch 11) terlihat jelas sebagai penurunan *loss* yang tajam, mengkonfirmasi efektivitas strategi *fine-tuning* dua fase. EfficientNet-B0 konvergen pada epoch ke-50 (validation accuracy 97.60%), sedangkan ResNet-18 konvergen lebih awal pada epoch ke-36, mencerminkan efisiensi pelatihan yang lebih baik.

D. Perbandingan dengan Penelitian Sebelumnya

Tabel VI mengontekstualisasikan penelitian ini dalam literatur pengenalan aksara Jawa yang ada. Penelitian ini adalah yang pertama mengevaluasi 120 kelas silabik pada dataset




Fig. 2. Kurva pelatihan EfficientNet-B0. Transisi Fase 1 ke Fase 2 terlihat pada epoch 11.




Fig. 3. Kurva pelatihan ResNet-18. Konvergensi yang lebih cepat dibandingkan EfficientNet-B0 (36 vs. 50 epoch).

tidak seimbang secara alami, sekaligus yang pertama melaporkan perbandingan empat arsitektur dengan analisis per kelompok vokal.

EfficientNet-B0 yang diusulkan mencapai akurasi sebanding dengan studi seimbang terdahulu (97.08% vs. 97.29% Susanto et al. [9]), meskipun dilatih pada dataset dengan ketidakseimbangan $33.10\times$. Hal ini mengkonfirmasi bahwa *pipeline* yang diusulkan berhasil menjembatani kondisi nyata yang tidak seimbang mendekati kinerja kondisi seimbang ideal. Selain itu, tidak ada studi sebelumnya yang melaporkan analisis per kelompok vokal, sehingga temuan mengenai kesenjangan generalisasi ResNet-18 yang hanya 0.0004 merupakan kontribusi yang sama sekali baru terhadap literatur ini.

Satu keterbatasan perlu diakui: setiap kelas Vokal non-A hanya diwakili 4 gambar dalam set pengujian, sehingga satu prediksi salah sudah menggeser F1 per kelas sebesar 25%. Oleh karena itu, seluruh kesimpulan didasarkan pada F1 makro per kelompok vokal (rata-rata 20 kelas), dan pengumpulan

TABLE VI
PERBANDINGAN DENGAN PENELITIAN PENGENALAN AKSARA JAWA

Studi	Kelas	Seimbang?	Metrik Terbaik
Susanto et al. [9]	120	Ya	Akurasi 97.29%
Susanto et al. [8]	120	Ya	Akurasi 99.65%
Ifriza et al. [5]	20	Ya	Akurasi 95.53%
Wisesty et al. [3]	20	Ya	F1 = 0.979
Nindya et al. [6]	20	Ya	Akurasi 93.19%
Faizin et al. [2]	20	Tidak	–
Usulan ini	120	Tidak	Akurasi 97.08%

data minoritas yang lebih besar menjadi prioritas penelitian lanjutan.

VI. KESIMPULAN

Penelitian ini menunjukkan bahwa pengenalan 120 kelas silabik aksara Jawa tulisan tangan pada kondisi ketidakseimbangan alami yang parah dapat dicapai dengan tingkat kinerja yang kompetitif melalui kombinasi *pipeline* persiapan data berbasis preservasi struktur dan *transfer learning*. EfficientNet-B0 mencapai akurasi 97.08% yang sebanding dengan studi-studi sebelumnya yang menggunakan dataset seimbang secara artifisial [9], membuktikan bahwa kondisi *imbalanced* bukan halangan yang tidak dapat diatasi dengan strategi data yang tepat.

Temuan yang secara analitis paling signifikan adalah kinerja ResNet-18, yang menunjukkan kesenjangan F1 antara kelas mayoritas dan minoritas hanya sebesar 0.0004 — sebuah keseimbangan generalisasi yang belum pernah dilaporkan dalam literatur aksara Jawa sebelumnya karena tidak ada studi terdahulu yang mengukur dimensi ini. Temuan ini memiliki implikasi praktis langsung: ketika sistem OCR aksara Jawa akan digunakan pada dokumen nyata yang mencakup seluruh spektrum vokal secara merata, ResNet-18 adalah pilihan yang lebih tepat dibandingkan arsitektur dengan akurasi agregat lebih tinggi namun bias terhadap kelas mayoritas.

Penelitian ini terbatas pada pengenalan karakter terisolasi dan set pengujian yang kecil untuk kelas minoritas. Ke depan, pengumpulan data minoritas yang lebih besar akan memperkuat validasi temuan ini, sementara eksplorasi augmentasi berbasis GAN [2] dapat melengkapi pendekatan fotometrik yang diusulkan. Perluasan ke pengenalan tingkat kata yang menyertakan bentuk *pasangan* merupakan langkah berikutnya yang paling relevan secara aplikatif [1].

DAFTAR PUSTAKA

- [1] B. A. Wicaksono, B. S. Hantono, and T. B. Adji, "Word segmentation task for Southeast Asian abugida scripts: A systematic literature review," in *Proc. 2024 2nd Int. Conf. Technology Innovation and Its Applications (ICTIIA)*, 2024.
- [2] M. A. Faizin, N. Suciati, and C. Fatichah, "Handling imbalance in Javanese manuscript character dataset using skeleton-based balancing generative adversarial networks," *Jurnal RESTI (Rekayasa Sistem dan Teknologi Informasi)*, vol. 9, no. 4, pp. 820–831, 2025.
- [3] U. N. Wisesty et al., "MNetNCR: MobileNet model for efficient traditional Nusantara script character recognition," *International Journal of Artificial Intelligence (IJ-AI)*, vol. 15, no. 2, pp. 1513–1528, 2026.
- [4] R. Widiarti and F. T. Adji, "A baseline evaluation of OCR segmentation and classification methods for printed Javanese script," *Engineering, Technology & Applied Science Research (ETASR)*, vol. 16, no. 1, pp. 31699–31705, 2026.
- [5] Y. N. Ifriza et al., "Optimizing Javanese script recognition using fine-tuned ResNet-18 and transfer learning," *International Journal of Artificial Intelligence (IJ-AI)*, vol. 15, no. 1, pp. 443–453, 2026.
- [6] T. P. Nindya, M. D. Sulistiyo, and U. N. Wisesty, "Recognition of Balinese, Javanese, and Sundanese scripts using CNN with VGG-16 architecture," in *Proc. 2025 Int. Conf. Data Science and Its Applications (ICoDSA)*, 2025, pp. 1221–1226.
- [7] M. D. Sulistiyo et al., "Aksarawa: Comparative study of shallow learning for OCR of Nusantara scripts," *Jurnal RESTI*, vol. 9, no. 6, pp. 1537–1546, 2025.
- [8] A. Susanto et al., "Handwritten Javanese script recognition method based 12-layers deep convolutional neural network and data augmentation," *International Journal of Artificial Intelligence (IJ-AI)*, vol. 12, no. 3, pp. 1448–1458, 2023.
- [9] A. Susanto, I. U. W. Mulyono, C. A. Sari, E. H. Rachmawanto, and D. R. I. M. Setiadi, "Improved Javanese script recognition using custom model of convolution neural network," *International Journal of Electrical and Computer Engineering (IJECE)*, vol. 13, no. 6, pp. 6629–6636, 2023.
- [10] A. Howard et al., "Searching for MobileNetV3," in *Proc. IEEE/CVF Int. Conf. Computer Vision (ICCV)*, 2019, pp. 1314–1324.
- [11] K. Simonyan and A. Zisserman, "Very deep convolutional networks for large-scale image recognition," in *Proc. Int. Conf. Learning Representations (ICLR)*, 2015.
- [12] K. He, X. Zhang, S. Ren, and J. Sun, "Deep residual learning for image recognition," in *Proc. IEEE Conf. Computer Vision and Pattern Recognition (CVPR)*, 2016, pp. 770–778.
- [13] M. Tan and Q. V. Le, "EfficientNet: Rethinking model scaling for convolutional neural networks," in *Proc. Int. Conf. Machine Learning (ICML)*, 2019, pp. 6105–6114.